EP2: Classificação de clareza no e-SIC

Ensemble calibrado e limites empíricos da tarefa

Cleben Garcia, João Pedro Marcondes, Luis Moraes, Renan Guimarães

Novembro 2026

ACH2118 | EACH-USP

Do EP1 ao EP2: lições e hipótese de trabalho

Diagnóstico do modelo do EP1

- Modelo anterior: fine-tuning de um único BERTimbau-base
- Acurácia no teste 1: 0,4867 (F1-macro: 0,4839)
- Limitações observadas:
  - Concentração excessiva de predições na classe majoritária (c5)
  - Recall baixo na classe intermediária c234 (38%)
  - 86 casos em que c1 foi confundido com c5 no teste 1
  - Uma única arquitetura atinge saturação precoce nesse vocabulário

Hipótese para o EP2

Combinar representações com padrões de erro descorrelacionados (BERTimbau para contexto semântico e ComplementNB para frequências de termos), corrigindo a distribuição a priori de probabilidades antes da decisão final.

0,4867
BERTimbau (EP1)

0,5078
Ensemble calibrado (EP2)

Evolução no teste 1:
+2,11 p.p.
Saldo de 19 acertos líquidos a mais

Tentativas descartadas e diagnóstico

Resultados das abordagens avaliadas no holdout antes da escolha final:

Família	Técnica investigada	Resultado no holdout
Pré-processamento	Remoção de saudações e assinaturas, minúsculas, truncagem	Acurácia caiu de 0,4565 para 0,4445. O cabeçalho identifica o órgão emissor.
Modelos ordinais	CORAL ordinal (projeções binárias com limiares ordenados)	A rede convergiu para nunca prever a classe intermediária c234.
Regras de decisão	Cascata de 2 estágios (separar neutro versus extremos)	AUC para neutro foi de 0,567. Apenas redistribui erros.
Limpeza de dados	Deduplicação e descarte de textos com rótulos conflitantes	Acurácia entre 0,4412 e 0,4429, sem ganho prático.
Modelos maiores	BERTimbau-large (0,4486) e mDeBERTa-v3-base	Não superaram o modelo base e aumentaram o custo de treino.

Diagnóstico: regras de decisão e ajustes de limiar apenas redistribuem a incerteza existente. O ganho prático veio da combinação de representações distintas.

Estrutura do ensemble híbrido

Ramo neural (contexto)

3 sementes do BERTimbau-base

(sementes 42, 1, 2; tamanho máx. 512; lr 2e-5)

$\rightarrow$ Média das probabilidades: P_{BERT}

+

Ramo linear (termos)

TF-IDF (1 e 2-gramas; min_df 2; sublinear)

ComplementNB ($\alpha = 0.3$)

Calibração de prior (w) $\rightarrow P_{\text{CNB}}^{\text{calib}}$

Votação suave ponderada:

$$P_{\text{final}} = 0,30 \cdot P_{\text{BERT}} + 0,70 \cdot P_{\text{CNB}}^{\text{calib}}$$

Diversidade de representação

- O BERTimbau capta relações sintáticas e semânticas globais
- O ComplementNB reage à presença de palavras específicas de cada domínio
- Os dois ramos apresentam correlação baixa de erros

Fusão calibrada

- Reduz a variância inerente a sementes neurais individuais
- Estabiliza predições nas fronteiras de decisão
- Pesos validados pelo protocolo em metades no holdout

Distorção empírica do estimador

- O ComplementNB estima parâmetros usando o complemento das classes
- Na tarefa do e-SIC, esse cálculo gerou uma distorção:
  - Previu c5 em 46% dos casos no conjunto de teste
  - Reduziu fortemente a revocação da classe central c234

Ajuste multiplicativo de prior

Multiplicação pontual pelo vetor de calibração w:

$$P_{\text{CNB}}^{\text{calib}}(c) = \frac{w_c \cdot P_{\text{CNB}}(c)}{\sum_j w_j \cdot P_{\text{CNB}}(j)}$$

com $w = [1,2, \quad 1,1, \quad 0,7]$ para `{c1, c234, c5}`.

Efeito isolado no teste 1

Versão do ComplementNB	Acurácia
Sem calibração	0,4711
Com calibração de prior	**0,5000**
Saldo	**+26 acertos**

- Conteve a superestimação da classe c5
- Elevou o número de acertos em c234 de 109 para 120
- Superou o modelo do EP1 de forma isolada

Validação em metades do holdout

Prevenção contra sobreajuste nos pesos

- Avaliar dezenas de combinações de pesos no holdout inteiro pode gerar estimativas otimistas
- O holdout estratificado de 20% (4.019 instâncias) foi dividido em duas metades independentes (A e B)
- Pesos ajustados na metade A e medidos na metade B: 0,4818
- Pesos ajustados na metade B e medidos na metade A: 0,4701
- Ambas as metades selecionaram a mesma composição (0,30 BERT e 0,70 CNB)

Treinamento para a submissão

- Validação do BERT: 10% do treino serviu exclusivamente para early stopping
- Modelo final: retreinado nos 20.092 exemplos de treino
- Teste 1: avaliado uma única vez para o teste de McNemar
- Teste 2: aplicado diretamente para produzir a planilha oficial de 897 instâncias, sem ajustes posteriores

Resultados no teste 1 (900 exemplos)

Abordagem avaliada	Acurácia	F1-macro	Ganho frente ao baseline
Classe majoritária (c5)	0,3333	–	−13,34 p.p.
Baseline oficial (RegLog + TF-IDF)	0,4667	–	Referência
ComplementNB sem calibração	0,4711	0,4621	+0,44 p.p.
BERTimbau único (EP1)	0,4867	0,4839	+2,00 p.p.
ComplementNB com calibração	0,5000	0,4938	+3,33 p.p.
Ensemble calibrado (EP2)	**0,5078**	**0,5056**	**+4,11 p.p.**

+4,11 p.p.
Acima do baseline oficial

+2,11 p.p.
Acima do modelo do EP1

0,5056
F1-macro equilibrado

Comparação estatística com o EP1

Tabela de contingência 2x2 (teste 1)

	EP2 certo	EP2 errado
EP1 certo	389	49
EP1 errado	**68**	394

- 117 casos discordantes no total:
  - 68 em que apenas o EP2 acertou
  - 49 em que apenas o EP1 acertou
- Saldo líquido de 19 acertos a favor do EP2

Teste de McNemar

- Estatística com correção de continuidade: $\chi^2 = 2,7692$ (1 gl), com $p = 0,0961$
- Teste binomial exato: $p = 0,0957$
- Significância marginal a 10%

Antes da calibração de prior, o p-valor era de 0,2765. O ajuste reduziu o valor para menos de 0,10.

Queda em erros opostos

Erros que trocavam c1 e c5 diretamente caíram de 86 para 53 casos (redução de 38%).

Pesos globais e identificadores de órgão

Termos mais influentes na regressão logística sobre TF-IDF (1 e 2-gramas):

Classe	Termos de maior peso positivo
`c1`	luis (+1,29), demanda (+1,28), solicitação (+1,27), essa informação (+1,12), sr luis (+1,06), nup (+0,96)
`c234`	sistemas (+1,40), prezado em (+1,21), territorial (+1,01), projetos (+0,96), extensão (+0,96), reitoria (+0,94)
`c5`	dnpm (+2,07), questionário (+1,89), sic dnpm (+1,61), solicitação encaminhamos (+1,55), odila (+1,19)

O classificador aprendeu procedência institucional

- Os termos de maior peso são siglas de órgãos (DNPM = Departamento Nacional de Produção Mineral), domínios temáticos (reitoria, concurso, territorial) e nomes de solicitantes ou servidores (luis, odila).
- O classificador utiliza a procedência como indicador indireto: órgãos públicos apresentam qualidades habituais distintas em suas respostas.
- Isso explica por que retirar saudações e rodapés prejudicou os resultados: o cabeçalho é justamente onde a identidade do órgão está registrada.

Interpretação local e análise de erros

Comportamento local das predições

- As contribuições individuais de palavras são baixas (valores abaixo de 0,13) e espalhadas por termos funcionais (de, que, uma)
- A decisão não se concentra em palavras-chave específicas de clareza
- Confiança média do modelo: 0,534 nos acertos e 0,486 nos erros
- O tamanho do texto não discrimina acertos e erros: média de 952 caracteres nos acertos e 950 nos erros

Casos concretos do teste 1

- **Linha 6 (c5 previsto como c234):** resposta com link direto da UFF atendendo à solicitação. O cidadão deu nota máxima, mas o modelo hesitou por fragmentos da URL (uff br, pdf).
- **Linha 0 (c5 previsto como c234):** explicação detalhada do IBGE sobre o Censo. O modelo reagiu ao tema censitário.
- **Linha 1 (c1 previsto como c234):** resposta protocolar do Ministério do Planejamento. O texto é gramaticalmente correto, mas não resolveu a demanda.

Sem a pergunta original e sem saber se a solicitação foi atendida, o texto da resposta sozinho não traz elementos para separar a nota 1 da nota 5.

Submissão do teste 2 e conclusões

Arquivo entregue: test2_ep2.xlsx

- 897 instâncias rotuladas sem valores ausentes
- Distribuição das predições geradas:
  - c1: 36,0% (323 instâncias)
  - c234: 23,5% (211 instâncias)
  - c5: 40,5% (363 instâncias)
- A calibração de prior evitou o esvaziamento da classe c234 e conteve a concentração em c5

Código e reprodutibilidade

- Scripts e notebooks disponíveis em: `github.com/clebenjr/ep1-ipln`

Conclusões do estudo

1. A clareza de uma resposta depende da pergunta feita e da expectativa do cidadão. Classificar apenas a resposta parte de uma entrada incompleta.
2. O teto de desempenho decorre do ruído humano na escala subjetiva (respostas com texto idêntico no treino receberam notas diferentes).
3. O ganho de 0,4667 para 0,5078 derivou da união de paradigmas complementares (BERT e n-gramas) com ajuste estatístico de prior.

Obrigado!

EP2: Classificação de clareza no e-SIC

ACH2118 - Introdução ao Processamento de Língua Natural

EACH - Universidade de São Paulo (USP)

Integrantes:

Cleben Junior Cosendey Garcia (14691220)

João Pedro Oliveira de Paula Marcondes (14582570)

Luis Henrique Moraes (14615590)

Renan Bezerra Guimarães (14605640)

Repositório: `https://github.com/clebenjr/ep1-ipln`